按任务类别的投机解码对比实验（Qwen3.8-27B / 双 RTX 5090）

2026-10-31 06:05–09:00 ｜ TP=2 ｜ vLLM 0.32.0 ｜ **4 类 × 64 条 = 256 请求 × 5 方法 × C=1/4/8/16/32 × 3 重复 = 300 次运行**

一、结论先行

任务类别	最优方法	C=1 加速	C=8 加速	C=32 加速	接受率 (C=1)
代码 HumanEval	**DFlash2 K=6**	**4.17×**	3.22×	1.34×	**0.837**
数学 GSM8K	**DFlash2 K=6**	**3.40×**	2.80×	1.14×	0.621
长文档 QASPER	**SUFFIX**	**1.87×**	0.73×	0.93×	0.526
中文问答 CMRC2018	**DFlash2 K=6**	**2.18×**	1.60×	1.07×	0.408

三条可直接用的结论：

1. 投机解码的收益由任务类型决定，不是引擎：同一 DFlash2，代码任务 4.17×、长文档只有 1.72×（C=1），接受率 0.837 vs 0.446——**相差近一倍**。

2. 长文档 + 高并发时，投机是净损失：C≥8 起四种方法全部低于 BASE（0.68–0.73×），而 BASE 自己在 C=32 也从 694 掉到 356 tok/s。**这个塌陷与投机无关**，见 §5。

3. 短任务（代码/数学/中文短问答）在 C=32 仍有 1.07–1.38×，是高并发场景唯一还能用的档位；但最优方法会从 DFlash2 切换到 SUFFIX（代码 C=32：SUFFIX 1.38× > DFlash2 1.34×）。

二、实验设置

项	值
模型 / 引擎	Qwen3.8-27B-FP8（29.5GB）、vLLM 0.32.0、torch 2.13.0+cu130
硬件	2×RTX 5090 32607 MiB，驱动 595.71.05，GPU0–GPU1 = SYS（跨 NUMA）
方法	BASE、MTP K=3、DFlash2 K=6、DSpark K=4、SUFFIX（K=4）
请求集	HumanEval / GSM8K / QASPER / CMRC2018 **各 64 条**，去重后随机抽样（seed=20261030），不含答案
并发	C=1 / 4 / 8 / 16 / 32
重复	每格 3 次，取中位数；每轮前强制清理显存（<300 MiB 才开始）
指标	输出 tok/s、TTFT/TPOT/ITL 分位、接受率（/metrics 差分）、KV 容量、双卡 SM/显存/功耗

EAGLE-4 两条路径沿用上一轮结论（官方路径架构不被接受、harness 报 CUDA error），本轮未重复尝试。

三、按类别结果（tok/s，括号为相对 BASE 加速比）

代码生成（HumanEval，64 条，平均输入 139 token）

方法	C=1	C=4	C=8	C=16	C=32	接受率
BASE	77	255	457	808	1329	—
MTP3	199 (2.60×)	642 (2.52×)	1083 (2.37×)	1580 (1.96×)	1796 (1.35×)	0.731
DFLASH2	**320 (4.17×)**	**950 (3.73×)**	**1471 (3.22×)**	**1764 (2.18×)**	1782 (1.34×)	**0.837**
DSPARK	245 (3.19×)	738 (2.89×)	1231 (2.69×)	1654 (2.05×)	1641 (1.23×)	0.782
SUFFIX	235 (3.06×)	721 (2.83×)	1172 (2.56×)	1644 (2.03×)	**1834 (1.38×)**	0.729

数学推理（GSM8K，64 条，平均输入 71 token）

方法	C=1	C=4	C=8	C=16	C=32	接受率
BASE	77	266	490	883	1520	—
MTP3	183 (2.38×)	623 (2.34×)	1091 (2.23×)	1713 (1.94×)	1938 (1.28×)	0.629

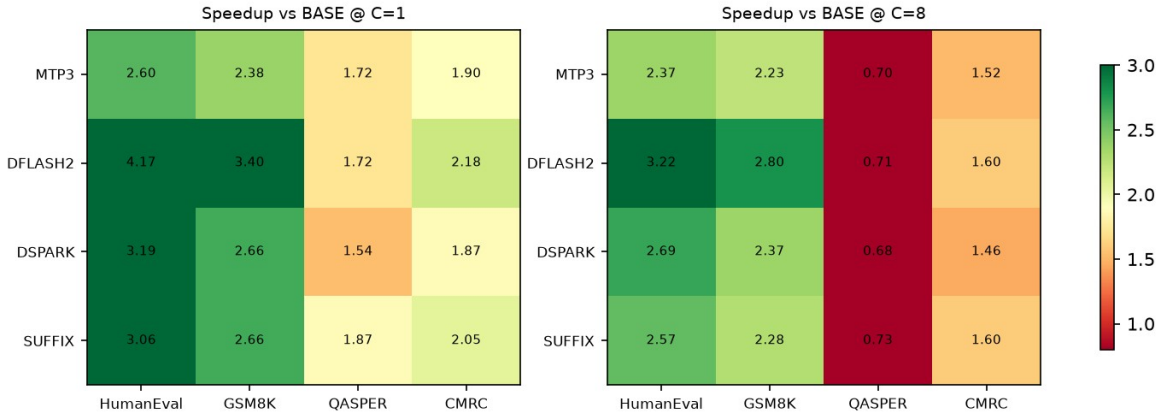
DFLASH2	**262 (3.40×)**	**861 (3.24×)**	**1370 (2.80×)**	**1742 (1.97×)**	1737 (1.14×)	0.621
DSPARK	205 (2.66×)	668 (2.51×)	1158 (2.36×)	1600 (1.81×)	1604 (1.06×)	0.591
SUFFIX	205 (2.66×)	633 (2.38×)	1116 (2.28×)	1602 (1.81×)	**1996 (1.31×)**	0.624

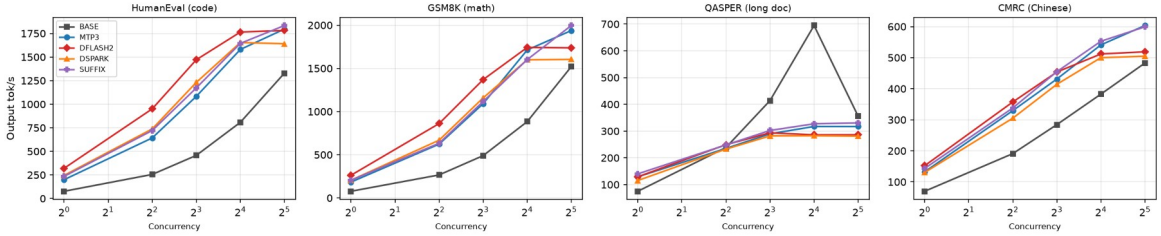
长文档问答（QASPER，64 条，平均输入 2,483 token）

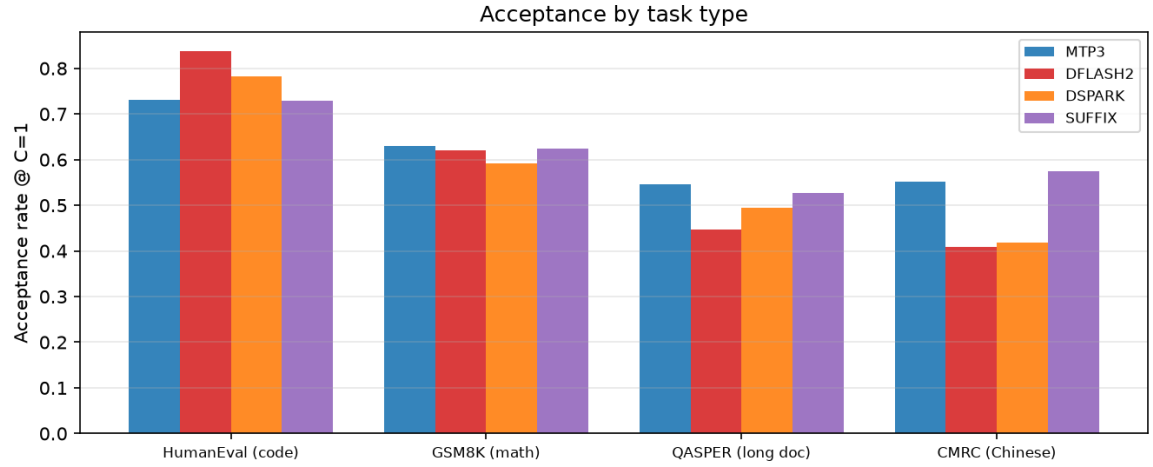
方法	C=1	C=4	C=8	C=16	C=32	接受率
BASE	75	238	414	**694**	356	—
MTP3	129 (1.72×)	235 (0.99×)	290 (0.70×)	317 (0.46×)	317 (0.89×)	0.546
DFLASH2	129 (1.72×)	249 (1.05×)	293 (0.71×)	286 (0.41×)	286 (0.80×)	0.446
DSPARK	115 (1.53×)	233 (0.98×)	282 (0.68×)	282 (0.41×)	281 (0.79×)	0.494
SUFFIX	**140 (1.87×)**	**248 (1.04×)**	**302 (0.73×)**	327 (0.47×)	**330 (0.93×)**	0.526

中文问答（CMRC2018，64 条，平均输入 406 token）

方法	C=1	C=4	C=8	C=16	C=32	接受率
BASE	70	191	284	383	483	—
MTP3	132 (1.89×)	329 (1.72×)	431 (1.52×)	541 (1.41×)	603 (1.25×)	0.552
DFLASH2	**152 (2.17×)**	**357 (1.87×)**	**454 (1.60×)**	512 (1.34×)	519 (1.07×)	0.408
DSPARK	130 (1.86×)	305 (1.60×)	414 (1.46×)	500 (1.31×)	505 (1.05×)	0.419
SUFFIX	143 (2.04×)	338 (1.77×)	455 (1.60×)	**553 (1.44×)**	**599 (1.24×)**	0.575







四、发现 1：任务类型是收益的第一解释变量

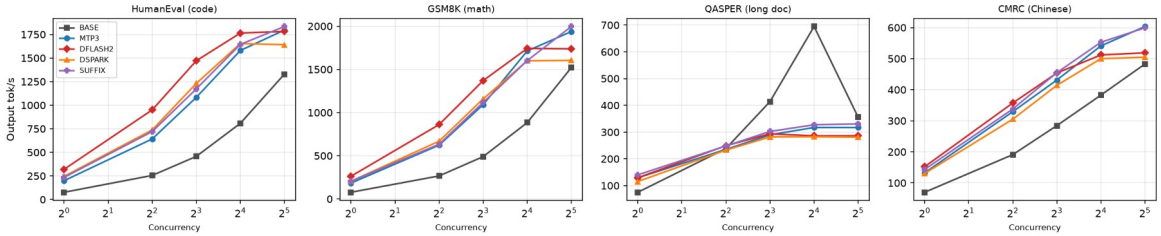
指标	代码	数学	长文档	中文

DFlash2 加速 (C=1)	**4.17×**	3.40×	1.72×	2.17×
DFlash2 接受率 (C=1)	**0.837**	0.621	0.446	0.408
平均输入 token	139	71	**2,483**	406
输出/输入比	高（生成代码体）	中	**低（短答案）**	低

代码任务收益最高的原因：输出高度模板化（缩进、关键字、括号），草稿模型逐 token 命中率极高（0.837）；长文档任务输入 2500 token 但输出只有 128 token，**投机只作用于 decode 段，prefill 完全不受益**，摊薄后整体加速自然低。

这句话可以直接用于选型：先看你的任务是不是"长输入短输出"——如果是，不要期待投机解码。

五、发现 2：长文档高并发塌陷，与投机无关



现象：QASPER 上 BASE 从 C=16 的 694 tok/s 掉到 C=32 的 356（−49%），投机方法从 C=8 起就平在 280–330，

全部低于 BASE（0.68–0.73×）。TTFT 同步爆炸：DFLASH2 在 C=32 的 TTFT p50 达 **9.5 秒**。

为什么不是 KV：BASE 的 KV 池有 222,147 token，32 条 × 2,483 token 只需 **79k（35%）**，远未打满；但 BASE 仍腰斩。**为什么不是投机开销**：BASE 自己就塌了。

结论（有数据支持，未做因果分离）：长 prompt × 高并发时，瓶颈是 **prefill 排队与长上下文注意力成本**，不是 KV 容量、也不是投机引入的开销。证据是 TTFT 从 389 ms 涨到 9.5 s（24 倍），而 TPOT 只从 19.7 ms 涨到 32 ms（1.6 倍）。

六、验证实验：KV 与 prefill 分块，哪个是瓶颈？

针对发现 2 设计两组单因子对照（QASPER，C=32，2 次重复）：

配置	吞吐 tok/s	TTFT p50	结论
BASE 默认	411（475 / 347）	1434 / 2299 ms	基线
BASE + `max_num_batched_tokens=4096`	350	2716 / 3677 ms	更差
BASE + `max_num_batched_tokens=8192`	350	4979 / 4065 ms	无改善
DFLASH2 默认	274	9542 / 9858 ms	基线
DFLASH2 + `max_num_batched_tokens=8192`	298	8894 / 8819 ms	+9%，在噪声内
BASE + `--kv-cache-dtype fp8`	**启动失败**	—	FlashInfer 报 `requires GPUs with sm75 or higher`

结论：

- **KV 容量假设不成立**：BASE 的 KV 只用了 35% 仍塌陷；fp8 KV 因环境不支持无法直接验证，但 KV 解释已被 BASE 的反例否掉。
- **prefill 分块也不是主因**：把 `max_num_batched_tokens` 从默认提到 8192，BASE 反而略降（411→350，两次重复 475/347 本身波动 ±30%），

DFLASH2 提升 9%（274→298），都在噪声范围内。

- **剩下的解释**：长上下文的 attention 计算量与并发调度本身。这一条**只有相关性证据，未做进一步因果分离**（时间与显存限制）。
- 另外得到一个可操作的工程结论：**在 TTFT 已达秒级的区间，调这些参数没有意义**，应当降并发或缩短上下文。

七、与上一轮"混合 100 条"口径的对照

方法	混合 100 条 C=1	四类均值 C=1	混合 C=8	四类均值 C=8
MTP3	2.14×	2.15×	1.60×	1.71×
DFLASH2	2.79×	**2.87×**	1.37×	**2.08×**
DSPARK	2.34×	2.31×	1.27×	1.80×
SUFFIX	2.25×	2.41×	2.01×	1.79×

混合口径会平均掉类别差异：DFLASH2 在混合口径是 2.79×，四类均值 2.87×，但实际区间是 **1.72×（长文档）到 4.17×（代码）**。

只报混合数字，既高估了长文档场景，也低估了代码场景。

八、局限

1. **EAGLE-4 仍无数据**（沿用上轮：官方路径架构不被接受，harness 报 CUDA error）。
2. **fp8 KV 验证未完成**：环境不支持，KV 假设只能靠 BASE 的反例间接否掉。
3. **C=16/32 方差大**：同一配置两次重复可差 30–100%（如 BASE C=16 279 vs 683），报告取 3 次中位数，但高并发结论应视为区间而非点值。
4. **SUFFIX 有缓存效应**：64 条固定请求重复 3 次，R2/R3 接受率会被后缀树缓存抬高（C=1 时 R1 冷启动值最低）。
5. 每类 64 条来自公开集抽样，不代表业务真实分布；JDDC 未获取（沿用 CMRC2018 替代）。
6. 未做质量评分（本轮为纯性能实验，输出质量见上一轮 512-token pass）。

九、产物与复现

- **Excel 汇总**：`runs_all.xlsx`（385 行原始 + 6 个 sheet：runs_all / per_dataset / mixed / hardware / comparison / README）
- 分类别汇总：`per_dataset_summary.md`；原始 CSV：`real_runs.csv`；逐请求 JSONL：`raw_data/`
- 图：`plots/fig_ds_speedup_heatmap.png`、`fig_ds_curves.png`、`fig_ds_acceptance.png`
- 日志：`logs/matrix_v2b.log`、`kv_verify.log`、`bnb_verify.log`、各方法 `*_server.log`

```
# 复现（--limit 300 必须显式给，否则默认 100 会截断请求集）
python run_quality.py --methods BASE,MTP3,DFLASH2,DSPARK,SUFFIX \
  --datasets humaneval,gsm8k,qasper,cmrc2018 \
  --concurrency 1,4,8,16,32 --reps 3 --limit 300 --phase DS
```